

Cómo construir un sistema serio para estimar grafts y simular un trasplante capilar

Sí es viable, pero hay que definir bien qué problema exacto resuelve el software. Si lo planteas solo como “contar grafts”, te vas a quedar corto. En una consulta real de primera visita, el médico no necesita únicamente un contador; necesita una herramienta que haga cuatro cosas: medir el estado actual, estimar la demanda de injertos, evaluar la oferta del área donante y mostrar una simulación visual razonable del resultado. Eso implica que el producto correcto no es un único modelo, sino una suite clínica de apoyo a consulta. Tu documento inicial va en la dirección correcta al separar detection, instance segmentation y density estimation, y es especialmente acertado al priorizar density estimation cuando hay alta densidad y solapamiento. Pero todavía le faltan varios bloques críticos: calibración clínica, estandarización de captura, planificación donante–receptor, simulación visual y estrategia regulatoria.

Qué existe hoy en el mercado

Ya hay software comercial que demuestra que la oportunidad es real. TrichoLAB ofrece análisis automatizado de tricoscopia y además un módulo de 3D transplant planning; HairMetrix de Canfield se posiciona como una consulta capilar no invasiva basada en IA; y TrichoSciencePro declara funciones muy cercanas a lo que describes: conteo de unidades foliculares, densidad, diámetros, áreas donante/receptora y cálculo de grafts necesarios/disponibles. Eso significa dos cosas. Primero: el problema tiene demanda clínica real. Segundo: si quieres entrar, no basta con “hacer conteo”; necesitas hacerlo mejor, más usable, más explicable o más barato que estas soluciones.

La tesis correcta del producto

La mejor tesis no es “IA que cuenta pelos”. La mejor tesis es:

Plataforma de planificación capilar asistida por visión por computador para consulta inicial y seguimiento, que cuantifica cobertura actual, estima necesidad de grafts, ayuda a diseñar hairline/zonas objetivo y produce una simulación visual con restricciones clínicas.

Ese framing es mejor porque te permite vender valor clínico y no solo una feature técnica. El cirujano no compra cajas delimitadoras; compra menos subjetividad, consulta más rápida, más conversiones, mejor documentación y mejor seguimiento.

El problema se divide en 4 motores distintos

1) Motor de medición diagnóstica

Este módulo analiza imágenes del cuero cabelludo o tricoscopia y estima:

- densidad capilar total
- densidad de unidades foliculares
- diámetro del pelo
- distribución terminal/vellus
- unidades foliculares de 1, 2, 3, 4 pelos
- cobertura por zonas
- miniaturización y heterogeneidad

La literatura reciente en tricoscopia ya muestra que deep learning puede medir densidad y distribución de diámetros automáticamente. Hay trabajos que usan CNN/Mask R-CNN para clasificar folículos y estimar severidad de alopecia, y otros que extraen variables tricoscópicas para clasificación clínica.

2) Motor de estimación de grafts

Este no sale “directamente” de una imagen. Sale de una función clínica que combine:

- área receptora
- densidad objetivo por subzona
- patrón de pérdida
- calidad de donante
- calibre del pelo
- color/contraste piel-pelo
- textura/lacio-rizado
- reserva para futuro
- límites seguros de extracción

Aquí es donde muchos prototipos fallan: creen que una red neuronal “ve” una foto y entrega el número de grafts. Clínicamente eso es incompleto. La necesidad de grafts depende de una mezcla de medición + reglas expertas + preferencias de diseño. La propia literatura de trasplante insiste en la lógica donante–receptor, diseño de hairline y límites de extracción segura; por ejemplo, las guías reportan recomendaciones generales de extracción segura por cm² y la importancia de planear con visión de largo plazo del área donante.

3) Motor de planificación visual

Este módulo segmenta el cuero cabelludo, define zonas y permite al médico dibujar o ajustar:

- frontal line / hairline
- frontal forelock
- midscalp
- crown
- temporal peaks
- áreas que no deben tocarse
- zona donante segura

Aquí necesitas UX clínica, no solo IA. El médico debe poder corregir manualmente. Si el sistema no permite override, pierde valor real.

4) Motor de simulación

Este es el más delicado. La mayoría de demos “wow” de IA generan imágenes bonitas, pero clínicamente peligrosas si no están restringidas. Ya existen plataformas comerciales de simulación estética y también ejemplos específicos de simulación de trasplante capilar, pero incluso en estética facial hay preocupación por expectativas irreales cuando la simulación generativa se interpreta como predicción quirúrgica.

La simulación correcta no debe prometer resultado. Debe ser presentada como:

- visualización orientativa
- escenario de cobertura estimada
- herramienta de comunicación médico–paciente
- no sustituto del juicio clínico

Qué parte de tu documento está bien y qué parte falta

Tu investigación base acierta en lo central: no siempre conviene detection; cuando hay alta densidad y solapamiento, density estimation o conteo con supervisión por puntos puede ser mucho más escalable que segmentación de instancia. Eso es consistente con literatura de

conteo en imágenes densas y también con problemas biomédicos donde las instancias pequeñas son numerosas y difíciles de separar. es esto:

1. Calibración espacial

No basta con contar objetos. Debes saber cuántos hay por cm². Sin eso, el número carece de significado clínico.

2. Pipeline multimodal

Las fotos normales sirven para simulación general. La tricoscopia sirve para medición fina. Son dos inputs distintos.

3. Separar counting de planning

El conteo no resuelve la necesidad de grafts por sí solo.

4. Diseño asistido, no totalmente automático

Hairline y densidades objetivo deben ser editables por el médico.

5. Estrategia regulatoria

Si el software procesa imágenes médicas con propósito clínico, ya entras en terreno regulatorio más serio.

La arquitectura técnica más sensata

Enfoque recomendado: sistema híbrido, no monolítico

La mejor arquitectura para una V1/V2 es esta:

Módulo A — Captura y estandarización

Inputs:

- foto frontal
- perfiles
- cenital
- occipital / donor
- macro o dermatoscopia/tricoscopia en puntos estándar

Debes imponer un protocolo:

- distancia fija
- iluminación controlada
- fondo neutro
- longitud de cabello máxima o estándar
- marcador de escala
- ángulo definido
- misma cámara o cámaras homologadas

Si no controlas captura, el modelo aprende ruido. Este punto parece aburrido, pero es determinante.

Módulo B — Segmentación anatómica

Modelos para segmentar:

- rostro
- línea de frente
- cuero cabelludo visible
- áreas con pérdida
- donor area
- áreas no seguras

Aquí sí puedes usar segmentación semántica o instance segmentation según la tarea. Para una V1, incluso un pipeline con SAM/MedSAM + correcciones manuales puede acelerar anotación y bootstrap interno, aunque para producción luego conviene entrenar modelos propios por consistencia.

Módulo C — Conteo / estimación de densidad

Aquí no usaría un solo enfoque.

Usaría una estrategia por escenario:

- Objetos relativamente separables → detection / point detection
- Folículos parcialmente fusionados → instance segmentation
- Alta densidad y microestructura → density estimation / point-supervised counting

Eso coincide con tu documento y con la práctica en conteo denso. Para imágenes de alta magnificación con muchísimos pelos o unidades visibles, los mapas de densidad y la supervisión por puntos son muy atractivos porque reducen costo de anotación y escalan mejor. engineering clínico

A partir del análisis anterior generas variables:

- área receptora estimada
- densidad actual por zona
- densidad donante por zona
- distribución de grafts por nº de pelos
- diámetro promedio
- ratio terminal/vellus
- índice de contraste
- score de miniaturización
- patrón tipo Norwood/Ludwig orientativo
- reserva donante

Módulo E — Motor de recomendación de grafts

Esto no lo haría como un LLM ni como puro generative AI.

Lo haría como una de estas dos opciones:

- Reglas clínicas parametrizadas + calculadora probabilística
- Modelo tabular supervisado entrenado con casos históricos de cirujanos expertos

La salida no debería ser un único número mágico, sino algo como:

- mínimo razonable
- rango recomendado
- rango agresivo
- advertencias por donante insuficiente
- sugerencia de cobertura por prioridad de zonas

Eso es mucho más clínicamente defendible.

Módulo F — Simulación visual restringida

Aquí la clave es restricción anatómica. No haría “text-to-image”. Haría algo así:

1. segmentar cuero cabelludo y pelo existente

2. detectar la línea frontal actual
3. generar una máscara objetivo de cobertura futura
4. aplicar síntesis capilar solo dentro de esa máscara
5. controlar densidad/ángulo/tono por zona
6. bloquear cambios en cara, piel, ojos, fondo e identidad

En otras palabras: image editing condicionado por máscara + parámetros clínicos, no generación libre. La investigación en hair transfer por difusión ha mejorado bastante, pero sigue siendo un campo donde la fidelidad visual no equivale a fidelidad clínica. Sirve como base técnica de simulación, no como predictor médico.

Qué stack técnico usaría de verdad

Si quieres construirlo rápido y bien

Frontend

- Web app: Next.js
- o desktop híbrido: Tauri o Electron
- para médico en consulta, prefiero web app privada o desktop local

sincronizable

Backend

- Python + FastAPI
- servicios separados:
- image pre-processing
- inference CV
- planning engine
- simulation engine
- report generation

Computer Vision

- PyTorch
- segmentation: U-Net / DeepLab / Mask R-CNN / YOLO-seg según tarea
- counting: CSRNet-like, U-Net density map, point-supervised counting
- detection: YOLOv8/YOLO11 small-object tuned o RT-DETR si el dataset lo

justifica

- postproceso geométrico para cm² y áreas curvas

Simulation

- pipeline con diffusion/image editing condicionado
- ComfyUI o backend propio si quieres iterar rápido
- pero con máscaras anatómicas y límites de edición

Data / MLOps

- DVC o lake sencillo versionado
- MLflow / Weights & Biases
- etiquetado con CVAT, Label Studio o supervisión asistida
- auditoría de datasets por dispositivo, fototipo, longitud de pelo y condiciones de

luz

Deployment

- si clinic-first: cloud privado + processing server
- si privacy-first: inferencia local opcional en Mac/Windows con modelo

cuantitativo y simulación remota

¿Web app o programa para Mac/Windows?

Web app

Pros

- despliegue rápido
- multi-sede
- onboarding más fácil
- actualizaciones centralizadas
- reportes y dashboards

Contras

- imágenes médicas y privacidad
- latencia si la simulación pesa
- integración con hardware local puede ser más incómoda

Desktop app

Pros

- mejor experiencia con cámaras/dermatoscopios USB
- más control offline
- mejor percepción de seguridad en clínica
- latencia baja en preprocesamiento

Contras

- mantenimiento doble si soportas Mac y Windows
- updates más complejos

Mi recomendación real

Haz esto en dos capas:

- V1: web app privada + backend cloud
- V2: desktop capture assistant para cámaras/dermatoscopios
- V3: modo offline enterprise

Para validar mercado, no empieces por desktop nativo completo. Empieza por web app clínica con flujo muy controlado.

Cómo lo construiría por fases

Fase 0 — Definir exactamente la promesa

No prometas “predicción exacta del resultado”. Promete:

- cuantificación objetiva inicial
- estimación asistida de grafts
- visualización orientativa
- reporte clínico-consultivo

Eso reduce riesgo técnico y legal.

Fase 1 — MVP clínico útil

La primera versión útil no necesita generative AI sofisticado.

Debe hacer:

1. subir fotos estandarizadas
2. segmentar scalp y áreas
3. permitir marcar hairline y zonas
4. estimar área receptora
5. medir densidad en puntos tricoscópicos
6. calcular rango de grafts sugerido
7. generar reporte PDF clínico

Si logras esto bien, ya tienes producto.

Fase 2 — Medición automatizada avanzada

Añades:

- conteo de follicular units por zona
- clasificación 1/2/3/4 hairs per FU
- score donante
- mapa de densidad del cuero cabelludo
- seguimiento longitudinal mismo punto/misma zona

Este tipo de cuantificación ya tiene anclaje en software comercial y literatura tricoscópica.

Fase 3 — Simulación restringida

Solo después de tener buen pipeline de medición.

La simulación debe apoyarse en:

- máscara de cobertura objetivo
- librería de patrones capilares realistas
- constraints por densidad objetivo
- blending respetando tono de piel, dirección y textura

Fase 4 — Inteligencia clínica

Con suficientes casos:

- recomendaciones según patrón de pérdida
- priorización de zonas
- escenarios conservador / balanceado / denso
- predicción de satisfacción o naturalidad por escenario
- comparación de planificación entre médicos

El núcleo algorítmico para estimar grafts

La fórmula clínica no debería ser secreta ni opaca. Debería ser explicable. Algo como:

Grafts requeridos $\approx \sum (\text{área_zona} \times \text{densidad_objetivo_zona} - \text{cobertura_actual_equivalente_zona}) \times \text{factores de corrección}$

Factores de corrección posibles:

- calibre del pelo
- rizo/curvatura
- contraste pelo-piel
- proporción de multi-hair grafts

- densidad nativa remanente
- prioridad estética de la zona
- edad y riesgo de progresión futura
- reserva donante

La literatura de trasplante deja claro que no todo se resuelve con “más grafts”; textura, calibre, color y selección de unidades afectan el resultado visible. Además, la extracción debe respetar límites seguros y planificación de largo plazo.

Lo más difícil no es el modelo: es el dataset

Necesitas un dataset clínicamente útil, no solo grande.

Datos que deberías recolectar

Por paciente:

- sexo
- edad
- etnicidad/fototipo si está permitido y éticamente justificado
- patrón de pérdida
- medicación actual
- longitud del pelo al capturar
- dispositivo/cámara
- iluminación
- fotos estándar de cabeza
- tricoscopia en puntos definidos
- evaluación del médico
- grafts finalmente recomendados
- grafts realmente implantados
- resultado postoperatorio a 6–12 meses

Etiquetas que importan

- segmentación de áreas capilares
- puntos o máscaras de follicular units
- densidad real medida
- clasificación terminal/vellus
- distribución de graft types
- hairline dibujada por experto
- score de calidad de donante
- graft range recomendado por experto
- resultado final y satisfacción

Sin esa última parte, tu motor de recomendación será técnicamente interesante pero clínicamente débil.

Estrategia de anotación correcta

Tu documento ya apunta bien al tema de costo de anotación. Yo haría esto:

Para densidad

- point annotations
- no cajas completas cuando haya microdensidad alta

Para segmentación anatómica

- máscaras por zona de scalp, donor y recipient

Para simulación

- pares before/after bien estandarizados
- metadata de grafts reales implantados
- no entrenar con before/after “marketing style” sin control

Para ahorrar costo

- active learning
- pseudo-labeling revisado por experto
- pre-annotación con SAM/detector
- human-in-the-loop con trichólogo/dermatólogo

Qué modelos probaría primero

No empezaría por el “state of the art más sexy”. Empezaría por baselines sólidos.

Para área y zonas

- U-Net
- DeepLabV3+
- YOLO segmentation si quieres rapidez de iteración

Para follicular unit counting en tricoscopía

- YOLO small-object baseline
- Mask R-CNN baseline
- density-map U-Net baseline

Para alta densidad

- U-Net de mapas de densidad
- CSRNet-like
- point-supervised counting con Bayesian loss o variantes modernas

Para simulación

- no entrenar de cero
- partir de un pipeline de image editing / hair transfer existente, pero restringido por máscaras y reglas

Qué métricas debes medir

No solo MAE.

Para medición

- MAE / RMSE de conteo
- error relativo por cm^2
- concordancia con expertos
- error por subgrupo: pelo oscuro/claro, lacio/rizado, corto/largo

Para segmentación

- IoU / Dice
- error de área

Para estimación de grafts

- MAE del rango recomendado vs experto
- cobertura del rango

- calibration error
- tasa de override médico

Para simulación

- preservación de identidad
- realismo percibido
- consistencia con densidad objetivo
- tasa de aceptación por médicos
- discrepancia entre simulación y resultado real, cuando haya follow-up

Riesgos técnicos que debes anticipar

1) El cabello tapa el cuero cabelludo

Si el pelo está largo, la medición de densidad se vuelve mucho menos confiable.

2) Las fotos sociales no son suficientes

Para Instagram-style inputs puedes simular, pero no deberías estimar clínicamente grafts sin protocolo mínimo.

3) La unidad folicular no siempre se separa visualmente

Especialmente en ciertas resoluciones y ángulos.

4) Curly / afro / canoso / alto contraste cambian el problema

Muchos modelos funcionan bien en pelo lacio oscuro y se rompen fuera de ese dominio.

5) La simulación puede mentir aunque se vea preciosa

Ese es probablemente el mayor riesgo de producto.

Riesgos regulatorios y legales

Aquí hay que ser frío: si tu software procesa o analiza imágenes médicas y genera recomendaciones para decisión clínica, puedes entrar en terreno de software as a medical device o, al menos, software clínico regulado según jurisdicción. FDA ha sido explícita en que software destinado a adquirir, procesar o analizar imágenes médicas para fines clínicos sigue siendo dispositivo en muchos escenarios; además, IMDRF mantiene marcos específicos para evaluación clínica de SaMD, y en 2025 IMDRF publicó principios finales de Good Machine Learning Practice para desarrollo de dispositivos médicos con ML.

Traducción práctica de eso

Si quieres venderlo como:

- “herramienta de marketing y visualización”

el riesgo regulatorio baja, pero debes limitar claims

Si quieres venderlo como:

- “estimador clínico cuantitativo para planificación quirúrgica”

el nivel de validación, documentación y gobernanza sube mucho

Mi recomendación: empieza como clinical consultation support tool, con claims prudentes y explicabilidad alta.

Mejor práctica de producto: médico siempre en el loop

La UI debe obligar a esto:

- el médico revisa
- corrige hairline
- corrige zonas
- ajusta densidades objetivo
- aprueba o edita el rango de grafts
- acepta el disclaimer de simulación

Eso no es una limitación. Es exactamente lo que hace el producto más defendible.

Mi recomendación de arquitectura de negocio/técnica

La mejor primera versión

No intentes lanzar “AI full autonomous hair transplant planner”.

Lanza:

Hair Planning Copilot for Clinics

Con estas funciones:

- captura guiada de fotos
- segmentación de zonas
- tricoscopia puntual
- densidad / FU analysis
- donor score
- graft estimation range
- hairline planning canvas
- visual simulation preview
- report generation

Eso sí se puede construir de manera seria.

Qué haría con Claude Code Opus 4.6 o Codex 5.3

Ambos te sirven, pero para este proyecto yo separaría roles:

Claude Code / Opus

Úsalo para:

- arquitectura del sistema
- documentación técnica
- diseño de flujos clínicos
- refactorings grandes
- escribir especificaciones
- prompts de labeling QA
- razonamiento sobre edge cases

Codex

Úsalo para:

- scaffold del backend
- endpoints FastAPI
- pipelines de inferencia
- utilidades de procesamiento de imagen
- integración frontend-backend
- tests
- scripts de entrenamiento y evaluación

Cómo trabajaría

1. primero redactas PRD + arquitectura + data spec
2. luego generas scaffold completo
3. luego construyes un baseline por módulo
4. después integras
5. por último la simulación generativa

Si empiezas al revés por la simulación, vas a perder meses.

Mi juicio final

Sí, esto tiene potencial real. Pero el éxito no está en “hacer una IA que cuente grafts”. Está en construir un sistema que combine:

- visión por computador para medición objetiva
- reglas clínicas explicables
- UX de planificación
- simulación visual restringida
- captura estandarizada
- human-in-the-loop

Tu nota inicial acierta en la parte de formulación CV del conteo, especialmente al diferenciar detection/segmentation/density estimation. Donde todavía está verde es en asumir implícitamente que el problema central es visual y unitario. No lo es. Es un problema mixto: visión, geometría, tricoscopia, planificación quirúrgica y comunicación con paciente. ndo

Opción correcta

Construir prim cuantitativo**, no una app generativa de marketing.

MVP concreto de 90 días

- carga de fotos estándar
- segmentación scalp/donor/recipient
- canvas de hairline manual asistido
- cálculo de área por zona
- carga de 3–5 imágenes tricoscópicas
- estimación de densidad / FU por cm²
- calculadora de grafts con reglas expertas
- reporte clínico

Después

- simulación visual condicionada
- seguimiento longitudinal
- benchmarking entre cirujanos
- dataset propietario

- validación clínica prospectiva

Si quieres, el siguiente paso útil es que te arme un blueprint completo del producto con:

- arquitectura técnica
- módulos
- stack
- schema de base de datos
- estrategia de dataset/anotación
- roadmap por fases
- y un master prompt para Claude Code o Codex para empezar a construirlo.